

# Weather vs Yield – Prognozowanie plonów rolnych na podstawie warunków pogodowych

GitHub: <https://github.com/bi3lu/weather-vs-yield>

# 1 WSTĘP

---

Rolnictwo od wieków pełniło istotną rolę w życiu człowieka, stanowiąc fundament bezpieczeństwa żywnościowego i rozwoju cywilizacji. Współczesne wyzwania, takie jak zmiany klimatyczne, niestabilność pogodowa oraz rosnące zapotrzebowanie na żywność, stawiają przed rolnictwem nowe wymagania. W odpowiedzi na te wyzwania, coraz częściej wykorzystuje się zaawansowane technologie, w tym uczenie maszynowe, do optymalizacji produkcji rolniczej i przewidywania plonów.

Projekt Weather vs Yield ma na celu stworzenie modelu regresyjnego, który pozwoli na prognozowanie wysokości plonów (t/ha) na podstawie danych pogodowych i agrarnych, takich jak opady, temperatura, nawadnianie, rodzaj gleby i uprawy. Takie podejście może wspierać rolników i decydentów w podejmowaniu świadomych decyzji dotyczących upraw, planowania zasobów oraz adaptacji do zmieniających się warunków klimatycznych.

## 2 DANE

---

Do realizacji projektu wykorzystano zbiór danych pochodzący z platformy Kaggle [1], zawierający około 100 000 rekordów z informacjami dotyczącymi:

- średnich rocznych opadów,
- średnich rocznych temperatur,
- nawadniania,
- rodzaju gleby,
- typu uprawy,
- wysokości plonów (t/ha).

Dane zostały podzielone na zestawy treningowe i testowe oraz poddane wstępnej analizie eksploracyjnej w celu identyfikacji zależności między zmiennymi. Wykorzystano również techniki inżynierii cech, takie jak kodowanie zmiennych kategorycznych i normalizacja danych numerycznych.

### 3 METODOLOGIA

---

W projekcie jako główny algorytm wykorzystano algorytm regresyjny jakim jest Random Forest (las losowy). Wcześniej przygotowany zbiór danych podzielono odpowiednia na zbiory: treningowy i testowy.

```
1. X_train = train_df.drop("Yield_tons_per_hectare", axis=1)
2. y_train = train_df["Yield_tons_per_hectare"]
3.
4. X_test = test_df.drop("Yield_tons_per_hectare", axis=1)
5. y_test = test_df["Yield_tons_per_hectare"]
6.
7. model = RandomForestRegressor(n_estimators=30, random_state=42)
8. model.fit(X_train, y_train)
```

*Listing 1 Fragment kodu prezentujący podział danych oraz trenowanie modelu*

Model został oceniony przy użyciu metryk takich jak:

- średni błąd bezwzględny,
- pierwiastek z błędu średniokwadratowego,
- współczynnik determinacji.

Uzyskano następujące wyniki – średni błąd bezwzględny (MAE) wyniósł 0.42, pierwiastek z błędu średniokwadratowego osiągnął wynik 0.52, natomiast współczynnik determinacji (R2) wyniósł 0.91, co oznacza, że model bardzo dobrze wyjaśnia zmienność plonów w danych testowych.

```
mae = mean_absolute_error(y_test, y_pred)
rmse = root_mean_squared_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print(f"MAE: {mae:.2f}")
print(f"RMSE: {rmse:.2f}")
print(f"R2: {r2:.2f}")
```

*Listing 2 Fragment kodu prezentujący wstępną ocenę wytrenowanego modelu*

*Output:*

MAE: 0.42


RMSE: 0.52

R2: 0.91

## 4 WYNIKI

Analiza ważności cech (feature importance) wykazała, że przy algorytmie Random Forest, największy wpływ na wysokość plonów miały [Rys. 1]:


- cecha F0 (średnia opadów deszczu w mm.),
- cecha F22 (użycie nawozu),
- cecha F23 (nawadnianie pola),
- cecha F1 (średnia temperatur),
- cecha F2 (czas do zbiorów).



Rys. 2 Wykres najważniejszych cech


Uzyskana w Eksploracji Danych macierz korelacji pokazuje, że [Rys. 2]:

- najwyższą dodatnią korelację uzyskała średnia opadów deszczu – wartość 0.76,
- stosowanie nawozów uzyskało umiarkowanie dodatnią korelację – 0.44,
- słabsza, chociaż wciąż pozytywna korelacja to nawadnianie – wartość 0.35,
- znikomą korelację uzyskała cecha opisująca średnią temperatur – 0.09,
- natomiast zerową korelację uzyskała cecha czas do zbiorów.




Rys. 2 Macierz korelacji numerycznych

W Eksploracji Danych uzyskano również wykres rozkładu zmiennej celu, w przypadku tego projektu jest to wartość zbiorów (tony na hektar pola). Rozkład zmiennej celu przypomina rozkład normalny (rozkład Gaussa) [Rys. 3], większość wartości znajduje się w przedziale 3–7 ton/ha, a szczyt rozkładu występuje w okolicach 5 ton/ha. Takie ukształtowanie rozkładu sprzyja stabilnemu działaniu modeli regresyjnych, ponieważ eliminuje problem asymetrii i wartości odstających.




Rys. 3 Wykres rozkładu plonów z surowego zbioru danych

W ewaluacji wytrenowanego oraz utworzonego modelu predykcji, uzyskano wykres „rzeczywistych vs przewidywanych” wartości końcowych [Rys. 4]. Wykres nie przedstawia bardzo dużych rozbieżności względem osi symetrii, co może nam mówić, że model jest dosyć dokładny.



Rys. 4 Wykres "rzeczywiste vs przewidywane"

Ostatnim uzyskanym wykresem – jest wykres rozkładu błędu predykcji [Rys. 5], pokazuje on, że model uzyskał maksymalny błąd w predykcji wyniku końcowego do maksymalnie 2 ton na hektar. Wynik taki jest w akceptowalnej granicy błędu bazując na tym, że zbiór danych posiada 100 tys. próbek z całej kuli ziemskiej, gdzie powierzchnie pól rolnych są zróżnicowane (np. w USA mamy do czynienia z ogromnymi połaciami upraw, natomiast w Polsce średnia wielkość pól uprawnych wynosi około 11.54 ha [2]).



Rys. 5 Wykres rozkładu błędu predykcji

## 5 PORÓWNANIE Z MODELAMI LIGHT GBM ORAZ XGBOOST

---

W projekcie zastosowano porównanie modelu opartego na algorytmie Random Forest z modelami opartymi o algorytmy Light GBM oraz XGBoost.

### 5.1 PORÓWNANIE Z LIGHT GBM

Model oparty na algorytmie Light GBM [3] został wytrenowany z następującymi parametrami:

- wartość `n_estimators` została ustawiona na 100,
- wartość `random_state` na 42.

```
1. model = LGBMRegressor(n_estimators=100, random_state=42)
2. model.fit(X_train, y_train)
```

*Listing 3 Fragment kodu prezentujący trenowanie modelu opartego na Light GMB*


Wstępna ocena modelu wygląda w następujący sposób:

- średni błąd bezwzględny (MAE) wyniósł 0.40, gdzie przy algorytmie Random Forest była to wartość 0.42,
- pierwiastek z błędu średniokwadratowego osiągnął wynik 0.50, gdzie model oparty na lesie losowym uzyskał 0.52,
- natomiast wartość R2 wyniosła 0.91, identycznie jak w modelu opartym o Random Forest.




W przypadku modelu opartego o Light GBM, najważniejsze cechy rozłożyły się w następujący sposób [Rys. 6]:

- cecha F0 (średnia opadów deszczu w mm.),
- cecha F1 (średnia temperatur),
- cecha F23 (nawadnianie pola),
- cecha F2 (liczba dni do zbiorów),
- cecha F22 (użycie nawozów),
- itd.




Rys. 6 Wykres najważniejszych cech w modelu opartym na Light GBM

Wykres rozkładu błędów predykcji [Rys. 7] kształtuje się podobnie jak przy algorytmie Random Forest, z bardzo minimalnymi odchyłami przy wartości 0 na osi Y.



Rys. 7 Wykres rozkładu błędów predykcji w modelu opartym na Light GBM

Natomiast wykres określający rzeczywiste vs przewidywane wyniki wygląda niemalże identycznie [Rys. 8] jak przy modelu z wykorzystaniem losowego lasu.



Rys. 8 Wykres "rzeczywiste vs przewidywane" w modelu opartym na Light GBM

Podsumowując – model oparty o algorytm Light GBM uzyskał bardzo zbliżone wyniki jak w modelu, który wykorzystywał losowy las do predykcji. Zauważono niewielkie odchyły np. w przypadku wykresu rozkładu błędu predykcji oraz w metrykach, we wstępnej ocenie modelu.

## 5.2 PORÓWNANIE Z XGBOOST

Model oparty o las losowy porównano również z modelem opartym o algorytm XGBoost [4]. Model został wytrenowany z następującymi parametrami:

- wartość `n_estimators` została ustawiona na 100,
- wartość `random_state` na 42,
- natomiast wartość `learning_rate` na 0.1.

```
1. model = XGBRegressor(n_estimators=100, learning_rate=0.1, random_state=42)
2. model.fit(X_train, y_train)
```


*Listing 4 Fragment kodu prezentujący trenowanie modelu opartego na XGBoost*

Wstępna ocena modelu wygląda w następujący sposób (model uzyskał identyczne wyniki jak model oparty o Light GBM):

- średni błąd bezwzględny (MAE) wyniósł 0.40, gdzie przy algorytmie Random Forest była to wartość 0.42,
- pierwiastek z błędu średniokwadratowego osiągnął wynik 0.50, gdzie model oparty na lesie losowym uzyskał 0.52,
- natomiast wartość `R2` wyniosła 0.91, identycznie jak w modelu opartym o Random Forest.


W przypadku tego modelu ważność cech [Rys. 9] rozłożyła się w sposób następujący:

- cecha F22 (użycie nawozu),
- cecha F23 (nawadnianie pola),
- cecha F0 (średnia opadów deszczu w mm.),
- cecha F1 (średnia temperatur).




Rys. 9 Wykres najważniejszych cech w modelu opartym na XGBoost

Wykres rozkładu błędów predykcji [Rys. 10] kształtuje się podobnie jak przy algorytmie Random Forest oraz Light GBM, również z bardzo minimalnymi odchyłami przy wartości 0 na osi Y. Ogólnie rzecz ujmując wszystkie trzy wykresy zbliżone są do rozkładu normalnego.



Rys. 10 Wykres rozkładu błędu predykcji w modelu opartym na Light GBM

Wykres określający rzeczywiste vs przewidywane wyniki wygląda niemalże identycznie [Rys. 11] jak przy poprzednich dwóch modelach.



Rys. 11 Wykres "rzeczywiste vs przewidywane" w modelu opartym na Light GBM

Model oparty o XGBoost w przypadku operowania na tym konkretnym zbiorze danych może z powodzeniem konkurować z Light GBM oraz losowym lasem drzew decyzyjnych. Wszystkie modele uzyskały względnie zbliżone wyniki.

## 6 WNIOSKI

---

Projekt Weather vs Yield potwierdził, że zastosowanie metod uczenia maszynowego w rolnictwie może znacząco poprawić dokładność prognozowania plonów, co jest kluczowe w kontekście zmieniających się warunków klimatycznych i rosnącego zapotrzebowania na żywność.

Model Random Forest okazał się efektywny w przewidywaniu plonów na podstawie danych pogodowych i agrarnych. W przyszłości warto rozważyć integrację dodatkowych źródeł danych, takich jak dane satelitarne czy informacje o praktykach rolniczych, aby zwiększyć dokładność prognoz i wspierać zrównoważone zarządzanie zasobami rolnymi.

Pozostałe dwa modele – Light GBM oraz XGBoost nie odstawały bardzo od modelu opartego o losowy las drzew decyzyjnych.



## 7 ŹRÓDŁA

---

- [1] <https://www.kaggle.com/datasets/samuelotiattakorah/agriculture-crop-yield/data> (stan na 23.05.2025 r.)
- [2] <https://www.gov.pl/web/arimr/srednia-powierzchnia-gruntow-rolnych-w-gospodarstwie-w-2024-roku> (stan na 23.05.2025 r.)
- [3] <https://lightgbm.readthedocs.io/en/stable/> (stan na 26.05.2025 r.)
- [4] [https://xgboost.readthedocs.io/en/release\\_3.0.0/](https://xgboost.readthedocs.io/en/release_3.0.0/) (stan na 26.05.2025 r.)